NILE PRIME · CONSULTORÍA DE IA

Conocer, recomendar y retener a la audiencia con inteligencia artificial

Informe de resultados de los cuatro retos: opiniones de los usuarios, recomendaciones personalizadas, riesgo de abandono y un recomendador que aprende de cada interacción.

Ali Alejandro Guerrero Jaimes
Máster en Data Science & Business Analytics · IMMUNE Technology Institute

Caso práctico · Inteligencia Artificial para la Empresa
11 de octubre de 2026

RESUMEN EJECUTIVO

Lo esencial en una página

Nile Prime quiere entender mejor a su audiencia para competir con las grandes plataformas. Analizamos sus datos y construimos cuatro soluciones de IA. Estos son los resultados.

RETO 1 · OPINIONES

91 de 100

reseñas clasificadas correctamente como positivas o negativas, de forma automática y en milisegundos.

RETO 2 · RECOMENDACIONES

×2,7

más aciertos que «recomendar lo más popular» cuando los usuarios tienen gustos definidos. En el histórico actual no hay gustos que aprender.

RETO 3 · ABANDONO

×2,0

más abandono en dos segmentos concretos: mayores con comedias puras (22,0 %) y jóvenes con dramas puros (20,6 %), frente al 10,3 % de media.

RETO 4 · APRENDIZAJE CONTINUO

27 → 0,05

abandonos por cada 1.000 recomendaciones en el simulador: el agente que aprende elimina casi todos los que provoca un recomendador estático.

Tres mensajes para la dirección

1. **Las opiniones ya se pueden leer a escala.**
   El clasificador de reseñas está listo para usarse: acierta 91,0 % de las veces, es rápido y barato de operar, y está ajustado para no dejar pasar quejas.

2. **El histórico de visualizaciones no revela gustos, y eso es un hallazgo.**
   Lo comprobamos con pruebas estadísticas: qué ve cada usuario se comporta como el azar. Ningún recomendador puede aprender de ahí, pero demostramos que el nuestro sí aprende cuando los gustos existen.

3. **Aprender en tiempo real es el camino.**
   El abandono depende de una combinación concreta de edad y tipo de película. Un agente que aprende de cada respuesta aprende a evitarla en pocas interacciones y deja de recomendar lo que la gente abandona.

Recomendación principal

Poner en marcha el clasificador de reseñas, probar con un experimento controlado la regla de negocio que hemos identificado sobre el abandono (una hipótesis a validar) y empezar a **registrar datos más ricos** (minutos vistos, fechas, valoraciones). Con esos datos, el recomendador y el modelo de abandono podrán dar todo su valor.

PUNTO DE PARTIDA

Qué datos teníamos y cómo trabajamos

Antes de construir nada, revisamos a fondo los datos. Lo que encontramos marcó las conclusiones de todo el proyecto.

Fuente	Volumen	Para qué sirve
Reseñas escritas por usuarios	50.000	Reto 1: entender la opinión del público.
Catálogo de películas (género, director, actores, sinopsis…)	999	Retos 2 y 4: describir el contenido.
Visualizaciones: quién vio qué y si llegó al final	100.624	Retos 2, 3 y 4: comportamiento de 10.000 usuarios.

Lo que descubrimos al revisar los datos

- **10,3 % de las visualizaciones se abandonan** antes del final. Es una minoría, así que un modelo que dijera siempre «no abandona» acertaría el 90 % de las veces sin servir para nada. Por eso medimos la calidad con indicadores que no se dejan engañar por eso.
- **No se registra cuánto tiempo ve cada usuario**, solo si terminó o no. Esa información es la que más ayudaría a anticipar el abandono.
- **Las reseñas no indican a qué película pertenecen**, así que el análisis de opiniones funciona como una herramienta independiente.
- Corregimos pequeños defectos: 422 reseñas repetidas, una película con el año mal escrito y dos películas distintas con el mismo título.

Cómo garantizamos que los resultados son fiables

Siempre contra una referencia

Cada modelo se compara con una alternativa simple (el azar, lo más popular…). Si no la supera con claridad, lo decimos.

Examen con datos nunca vistos

Los modelos se ajustan con una parte de los datos y se evalúan, una sola vez, con otra parte reservada.

Margen de error explícito

Cada cifra va acompañada de su rango de confianza y las diferencias se someten a pruebas estadísticas.

Todo el análisis es reproducible: los cuadernos de código entregados regeneran cada cifra y cada gráfico de este informe.

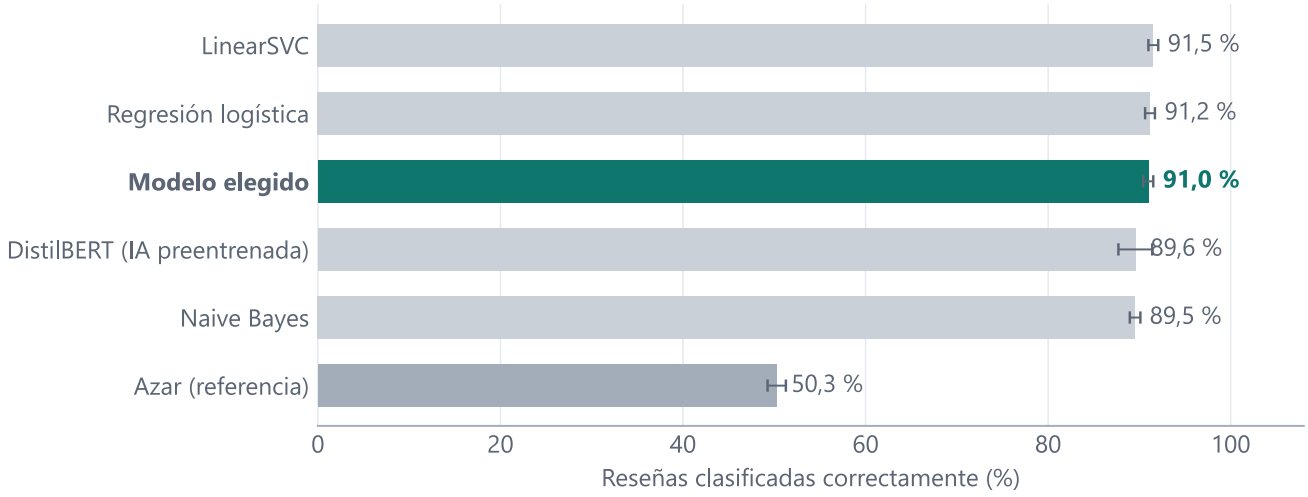
RETO 1 · ANÁLISIS DE SENTIMIENTO

Leer miles de opiniones en segundos

El problema: nadie puede leer decenas de miles de reseñas. Necesitamos saber de forma automática si cada opinión es positiva o negativa, para detectar a tiempo el descontento.

Qué hicimos

Entrenamos y comparamos varios modelos con 49.578 reseñas reales. Incluimos un modelo de IA moderno ya entrenado por terceros (DistilBERT), para comprobar si merecía la pena su mayor coste. Cada modelo se evaluó con 9.916 reseñas que no había visto antes.



Porcentaje de reseñas clasificadas correctamente, con su margen de error. El modelo elegido aparece en verde.

Resultado

- El modelo elegido acierta en **91,0 %** de las reseñas (rango probable: 90,4 %–91,5 %). Elegir al azar acertaría la mitad.
- La IA preentrenada no es mejor (89,6 %) y es unas **18 veces más lenta**: no compensa su coste.
- **Ajustado para no dejar pasar quejas.** Dejar sin detectar una reseña negativa cuesta más que revisar de más una positiva (supusimos el doble). Por eso el modelo exige más seguridad antes de dar una opinión por positiva. Sacrificamos unas décimas de acierto global a cambio de detectar más descontento.

Qué puede hacer Nile Prime con esto

Clasificar automáticamente cada reseña nueva, medir la satisfacción por película o por semana y alertar al equipo de contenidos cuando crezcan las opiniones negativas. Funciona en un ordenador normal, sin infraestructura especial.

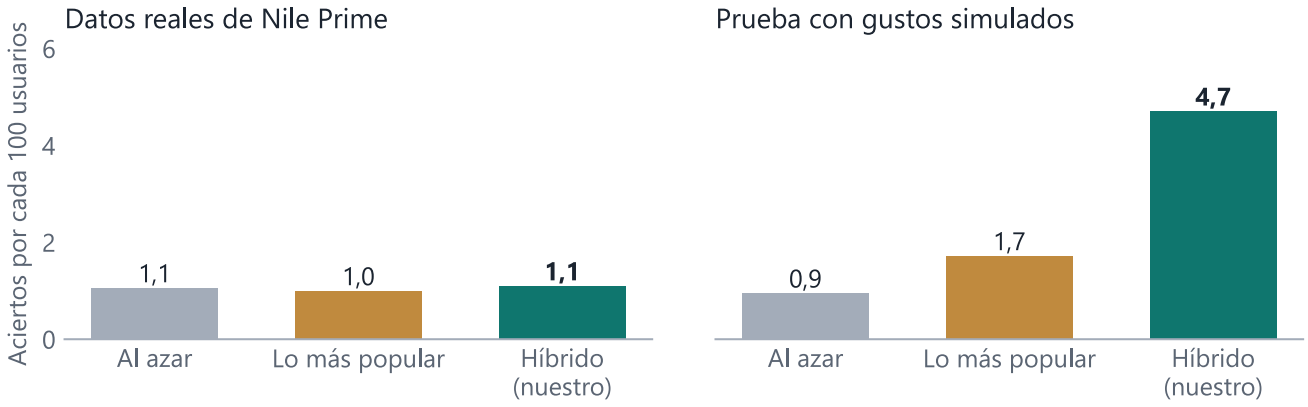
RETO 2 · RECOMENDACIÓN PERSONALIZADA

Un recomendador listo para cuando haya gustos que aprender

El problema: mostrar a cada usuario las películas que más probablemente quiera ver, combinando lo que sabemos de las películas con lo que hacen usuarios parecidos.

Qué hicimos

Construimos un **recomendador híbrido** que mezcla dos ideas: «películas parecidas a las que viste» (por género, director, reparto y sinopsis) y «lo que vieron personas con un historial parecido al tuyo». Lo comparamos con dos referencias simples: recomendar al azar y recomendar lo más popular.



Cuántas veces, de cada 100 usuarios, la película que el usuario vio de verdad aparece entre las 10 recomendadas. Izquierda: datos reales. Derecha: los mismos usuarios con gustos simulados.

Resultado: un hallazgo importante sobre los datos

- **Con los datos reales, ningún método supera al azar** (alrededor de 1,1 aciertos por cada 100 usuarios). Investigamos por qué: las películas que ve cada usuario no comparten género, director ni público entre sí más de lo que lo harían al azar. **El historial no contiene gustos que aprender.**
- Para comprobar que el problema está en los datos y no en el recomendador, **simulamos usuarios con gustos definidos**. Ahí el híbrido acierta **2,7 veces más** que recomendar lo más popular, una diferencia estadísticamente muy sólida cuando los gustos simulados son marcados; con gustos débiles la ventaja es pequeña.
- Además, el híbrido **aprovecha todo el catálogo** (100 % de los títulos aparece en alguna recomendación, frente al 1,4 % de «lo más popular») y sabe recomendar **películas recién añadidas**, que todavía nadie ha visto.

Qué significa para Nile Prime

El recomendador está construido y probado. Para que aporte valor real hace falta registrar señales de gusto más ricas: valoraciones, minutos vistos, búsquedas o «me gusta». Mientras tanto, el aprendizaje continuo del reto 4 es la vía para descubrir preferencias.

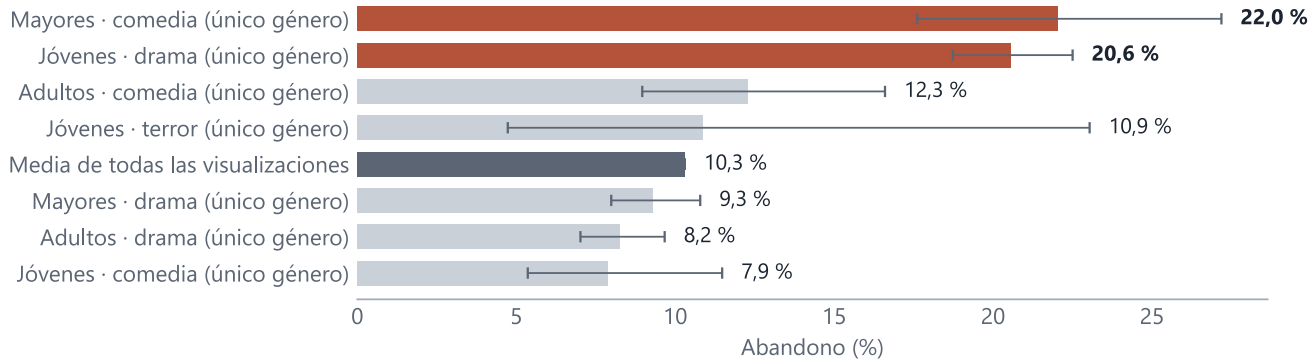
RETO 3 · PREDICCIÓN DE ABANDONO

Dónde está el riesgo de que no terminen la película

El problema: anticipar qué visualizaciones se van a abandonar para poder actuar antes, por ejemplo recomendando otra película más adecuada.

Qué hicimos

Entrenamos un modelo de **Random Forest** (cientos de árboles de decisión combinados) con las características de cada película (duración, año, valoración, géneros) y del usuario (grupo de edad), y comprobamos que lo que detecta no es casualidad.



Abandono por grupo de edad en películas de un único género, con su margen de error. En rojo, los segmentos que superan claramente la media.

Resultado

- **El riesgo existe, pero está muy concentrado.** El abandono se duplica en combinaciones concretas: los **jóvenes con dramas «puros»** (películas cuyo único género es drama) y los **mayores con comedias puras**. En el resto del catálogo el abandono es prácticamente igual para todos.
- El modelo encuentra esa señal (prueba estadística: p = 0,020) y aprovecha prácticamente toda: su capacidad de ordenar por riesgo (0,523) está a la altura del máximo estimado que daría conocer la regla exacta con la que se comportan los datos, que identificamos al revisar el simulador (0,518). Como el riesgo afecta a pocas visualizaciones, la predicción caso a caso es débil: el 10 % de visualizaciones que el modelo marca como más arriesgadas abandona un 13,6 %, frente a un 9,8 % en el resto. Con las variables disponibles apenas queda margen para hacerlo mejor.
- **Hoy no compensa lanzar acciones de retención usuario por usuario.** Con los costes supuestos (no detectar un abandono cuesta 3 veces más que una acción innecesaria), lo óptimo es no intervenir. Actuar solo sobre los segmentos de riesgo compensaría si perder una visualización costara más de 3,9 veces lo que cuesta la acción.

Qué puede hacer Nile Prime con esto

Probar con un experimento controlado una **regla sencilla**: no priorizar dramas puros en las recomendaciones a jóvenes ni comedias puras a mayores, y ampliarla solo si reduce el abandono. Es una hipótesis: con los costes supuestos todavía no está justificado actuar. Y empezar a registrar **en qué minuto se abandona**: es el dato que más mejoraría la predicción.

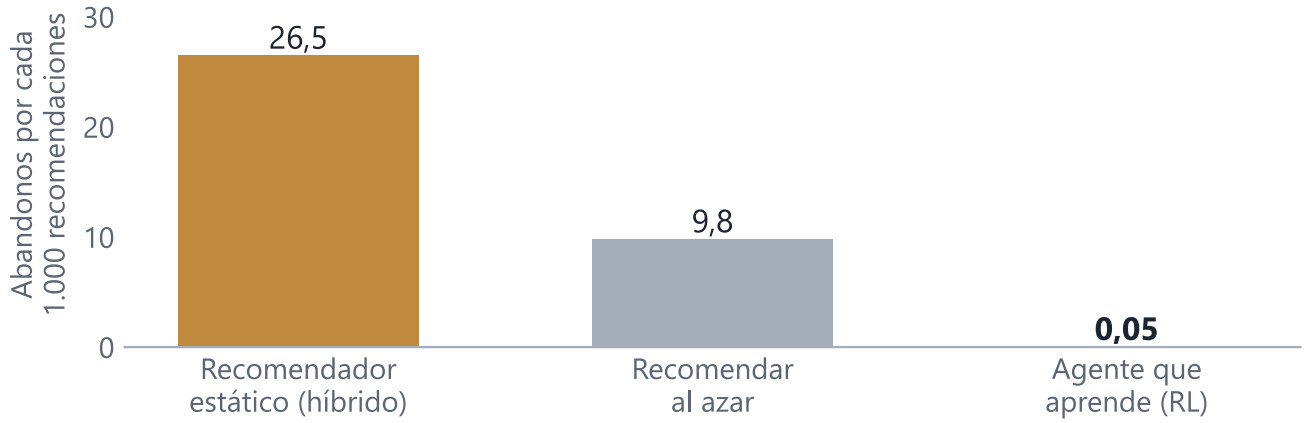
RETO 4 · APRENDIZAJE POR REFUERZO

Un recomendador que aprende de cada respuesta

El problema: si el histórico no enseña los gustos, ¿cómo mejorar las recomendaciones? Dejando que el sistema aprenda probando y observando si el usuario termina la película.

Qué hicimos

Usamos el simulador de usuarios proporcionado, que imita cómo reaccionan los usuarios a una recomendación. Primero lo reparamos: tenía **dos fallos que impedían usarlo**, y los corregimos sin cambiar sus reglas. Después entrenamos un **agente de aprendizaje por refuerzo** (Q-learning). El agente recomienda, observa si el usuario termina la película y ajusta sus preferencias, como haría una persona aprendiendo por experiencia. Repetimos cada experimento 10 veces.



Abandonos provocados por cada 1.000 recomendaciones en el simulador, una vez que el agente ha aprendido.

Resultado

- El recomendador estático del reto 2 **provoca más abandonos que recomendar al azar** (26,5 frente a 9,8 por cada 1.000), porque sugiere con mucha frecuencia dramas puros, que son justo los que los jóvenes abandonan. No se diseñó pensando en el abandono.
- El agente que aprende **baja a 0,05 abandonos por cada 1.000**, prácticamente el óptimo, y aprende a evitar el contenido problemático en unas 3 interacciones por grupo de edad.
- Aprende **por sí solo a evitar el mismo tipo de contenido** que el modelo de abandono señaló en los datos históricos. Para identificar el segmento completo, y no solo esquivarlo, necesita miles de interacciones.
- En un escenario más exigente, en el que penalizan todas las películas que *incluyen* esos géneros, la mejora es mayor: 13,0 puntos más de películas vistas hasta el final que con el recomendador estático.

Qué puede hacer Nile Prime con esto

Llevar este enfoque a producción de forma gradual: un pequeño porcentaje de recomendaciones lo gestiona el agente que aprende, se compara con el sistema actual y, si mejora la tasa de películas terminadas, se amplía.

CONCLUSIONES

Cómo encajan las piezas y próximos pasos

Los cuatro retos cuentan una misma historia: con los datos actuales, la ventaja está en leer opiniones y en aprender en tiempo real.

Escuchar

El clasificador de reseñas mide la satisfacción a escala y alerta del descontento.

Entender el riesgo

El abandono se concentra en combinaciones de público y tipo de película identificadas.

Aprender y adaptar

El agente de aprendizaje aprende solo a evitar esas combinaciones al recomendar.

Hoja de ruta recomendada

1. **Inmediato · Desplegar el clasificador de reseñas.**
   Panel semanal de satisfacción por título y alertas de opiniones negativas.
2. **Inmediato · Probar la regla de abandono (experimento A/B).**
   No priorizar dramas puros para jóvenes ni comedias puras para mayores en un grupo de prueba, y medir si baja el abandono.
3. **1–3 meses · Registrar mejores datos.**
   Minutos vistos y momento del abandono, fecha y hora, dispositivo, valoraciones explícitas y título asociado a cada reseña.
4. **3–6 meses · Aprendizaje continuo en producción.**
   Desplegar el agente de forma gradual y controlada, y reentrenar el recomendador y el modelo de abandono con los nuevos datos.

Limitaciones que conviene conocer

- Los datos de visualizaciones se comportan como si se hubieran generado al azar: no reflejan gustos reales, lo que limita lo que cualquier modelo puede aprender de ellos.
- Los costes de equivocarse (quejas no detectadas, acciones de retención) son supuestos razonables. Nile Prime debería sustituirlos por sus cifras reales.
- El aprendizaje por refuerzo se evaluó en un simulador. Su efecto real debe confirmarse con usuarios mediante experimentos controlados.
- El simulador es más optimista que los datos: fuera de los segmentos de riesgo nadie abandona, cuando en el histórico lo hace un 10 %. Con tasas de abandono como las observadas, la mejora sobre el recomendador estático baja a 0,9 puntos.
- El modelo de IA más grande disponible (RoBERTa) no se evaluó por falta de tarjeta gráfica. Dado el resultado de DistilBERT, no se espera que cambie la recomendación.

ANEXO

Glosario y contenido técnico entregado

Acierto (exactitud)
Porcentaje de casos que el modelo clasifica correctamente.

Margen de error / rango probable
Intervalo en el que, con un 95 % de confianza, se encuentra el valor real de una cifra.

Prueba estadística (p)
Mide la probabilidad de ver un resultado así por pura casualidad. Cuanto más pequeña, más fiable es la diferencia (habitualmente, menos de 0,05).

Capacidad de ordenar por riesgo (AUC)
Indicador de 0,5 (como lanzar una moneda) a 1 (perfecto) que mide si el modelo pone los casos de riesgo por delante.

Recomendador híbrido
Combina «películas parecidas» (contenido) con «lo que vieron usuarios parecidos» (comportamiento).

Gustos simulados
Datos generados a propósito con preferencias conocidas, para comprobar que un método es capaz de descubrirlas.

Aprendizaje por refuerzo
Técnica en la que un sistema aprende probando acciones y recibiendo una recompensa (aquí, que el usuario termine la película).

Random Forest
Modelo que combina muchos árboles de decisión y vota el resultado. Es robusto y permite ver qué variables pesan más.

Material técnico

Cuaderno	Contenido
00 · EDA y preparación	Calidad de datos, pruebas estadísticas de abandono y de estructura de preferencias.
01 · Sentimiento	Comparación de modelos de texto, calibración, umbral por coste y análisis de errores.
02 · Recomendador	Modelos por contenido, colaborativo e híbrido; evaluación reservando una película por usuario, pruebas estadísticas y gustos simulados.
03 · Abandono	Random Forest, prueba de permutación, calibración, umbral por coste e importancia de variables.
04 · Aprendizaje por refuerzo	Corrección del simulador, política óptima, Q-learning y comparación con el recomendador estático.

Cifras generadas automáticamente a partir de los resultados de los cuadernos (reports/metrics/*.json (modo full)).